Условие задания

Цель ДЗ

Спроектировать и реализовать model registry с нуля.

Сетап

Дано несколько ML-команд, которые обучают модели и складывают их в директорию на определенную машинку.

Текущее состояние хаоса представляет собой примерно такую структуру:

```
models/
models/mlds_1/my_model_v1/
models/mlds_3/sft_modell_v_123/
models/mlds_180/model_v1_v0_with_rank_dataset_0/
models/mlds_180/model_v1_v0_with_rank_dataset_1/
models/mlds_180/model_v1_v0_without_rank_dataset_0/
models/mlds_180/model_v1_v0_without_rank_dataset_1/
```

Больше информации по моделям нет никакой, только папки.

Что вам нужно сделать

- Сформулировать существующие проблемы, зафиксировать их.
- На их основе продумать функциональные и нефункциональные требования к системе хранения моделей, зафиксировать эти требования.
- На основе требований спроектировать архитектуру системы, отобразить ее в виде схемы, обосновать все компоненты и выбор технологий.
- Продумать API и схему БД.
- Реализовать спроектированную систему.

Существующие проблемы

Полное отсутствие метаданных

Команды складывают модели в папки, которые не имеют четкой структуры создания имени, из которой можно было бы получить информацию о модели: какой датасет обучения, метрики качества и гиперпараметры. Это полностью убивает возможность воспроизводить эксперименты.

Отсутствие версионирования

Исходя из примеров, разные команды по разному пытаются версионировать модели с помощью нейминга папок, но как не трудно заметить, получается у них это плохо: разные команды по разному называют папки. Все это приводит к бардаку, в котором определить версию модели невозможно.

Отсутствие информации о жизненном цикле модели

Не понятно, в каком состоянии находится модель: что сейчас на проде, а что уже устарело.

Не понятно, кто что делал

В примере команды создают свою папку, но в ручном формате это может привести к путанице: не понятно, `mlds_180` это 18 или 180 команда? Из-за отсутствия общего регламента написания папок рано или поздно случится бардак в каталогах.

Требования к системе

Функциональные требования

Регистрация и хранение

- Регистрация модели с обязательными метаданными: название модели, команда, автор, что за задача.
- Загрузка артефактов модели
- Загрузка метрик качества для каждой версии модели
- Привязка информации о датасете и параметрах обучения

Версионирование

- Автоматическая нумерация версий при регистрации новой версии модели
- Возможность просмотра истории версий

Жизненный цикл

- Хранение статуса жизненного цикла модели
- Возможность менять статус
- Только одна версия может быть Production одновременно

Каталог и поиск

- Поиск по параметрам модели (название, команда, задача и т.д.)

Аудит

- Логирование любых изменений моделей

Контроль доступа

- Команды могут управлять только своими моделями
- Смена статуса в Production требует прав admin или team-lead

Нефункциональные требования

Надёжность

- Артефакты моделей не должны теряться.

Масштабируемость

- Система должна выдерживать рост числа моделей и быть готовой к хранению больших файлов.

Производительность

- Чтение метаданных из API должно быть достаточно быстрым.
- Загрузка и скачивание артефактов должно работать напрямую из хранилища.

Эксплуатация

- Логирование всех запросов к API.

Архитектура системы

Схема

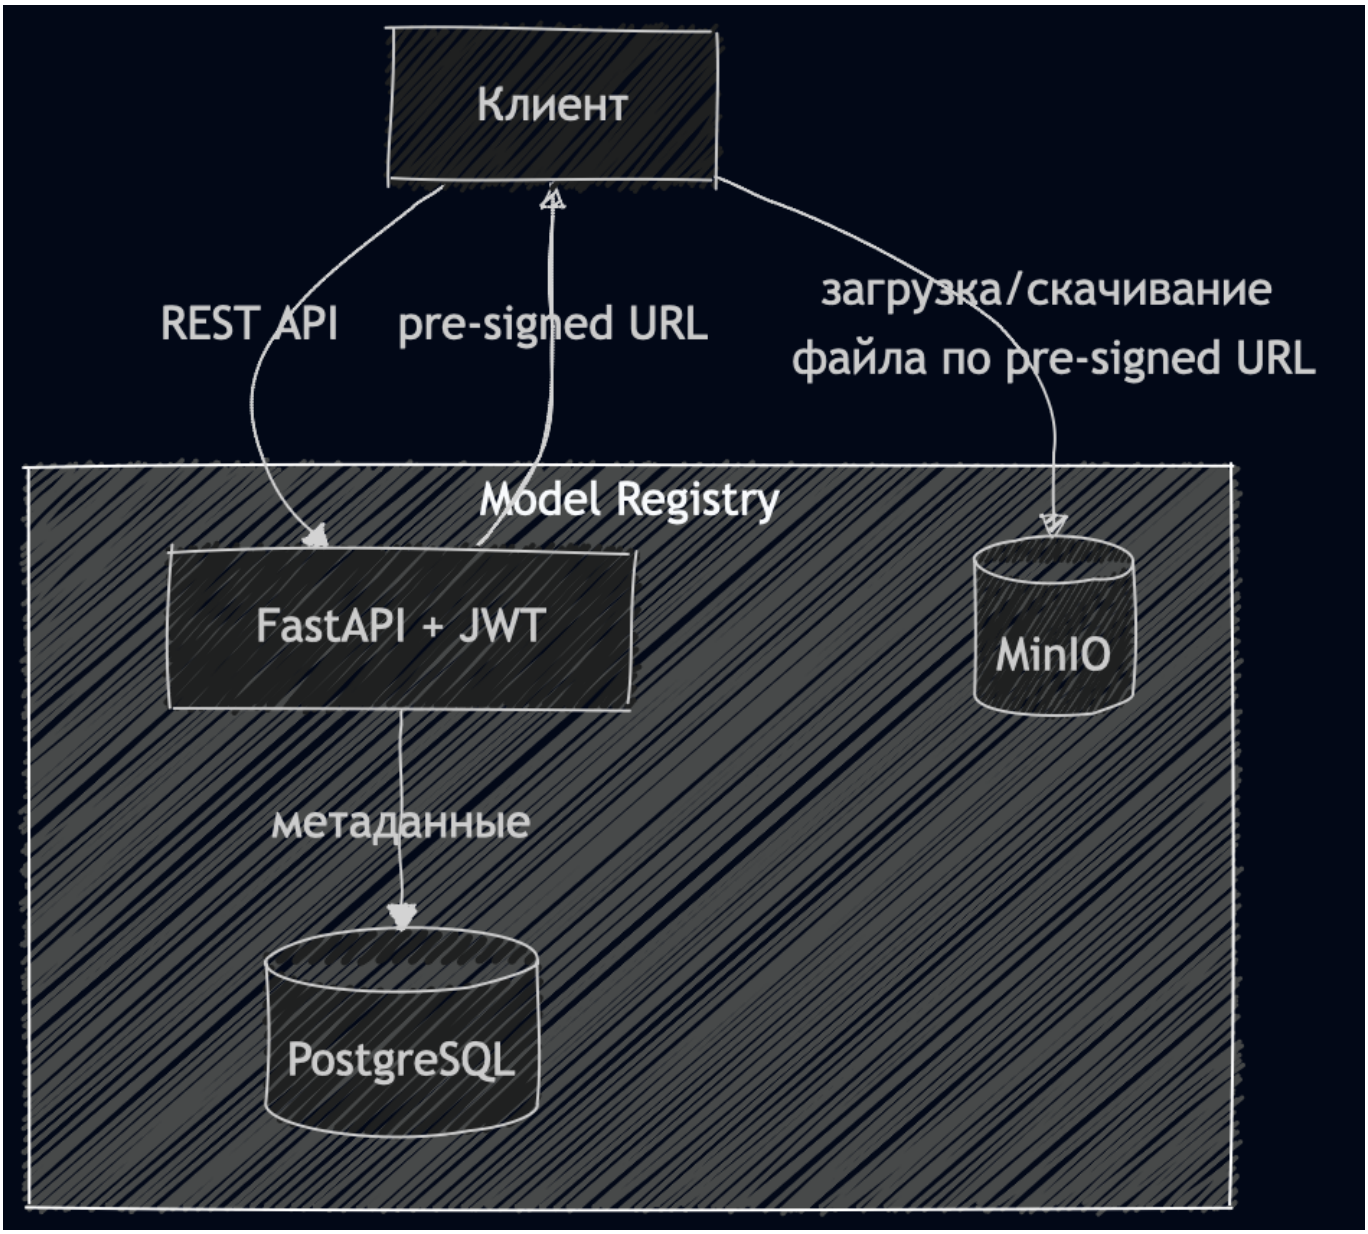

Клиент обращается к FastAPI. Метаданные хранятся в PostgreSQL, бинарные артефакты — в MinIO. Для загрузки/скачивания файлов API возвращает pre-signed URL, и клиент работает с MinIO напрямую.

Компоненты

Компонент	Технология	Обоснование
REST API	FastAPI	простой и быстрый фреймворк, хорошо работает из коробки. Идеальный выбор для небольшого проекта.
Авторизация	JWT	Удобно реализовать в FastAPI, не обязательно хранить сессии
Метаданные	PostgreSQL	Легкий и простой старт, поддержка JSONB для хранения метаданных
Артефакты	MinIO	удобный и простой S3 для домашнего компьютера
Оркестрация	Docker Compose	простой запуск всех сервисов одной командой, кубер был бы избыточен для такого задания

API

Аутентификация

Метод	Путь	Описание
POST	`/auth/login`	Получить JWT-токен
POST	`/auth/register`	Зарегистрировать пользователя в бд

Все остальные эндпоинты требуют заголовок `Authorization: Bearer <token>`.

Модели

Метод	Путь	Описание	Права
POST	`/models`	Зарегистрировать модель	любой
GET	`/models`	Список моделей с фильтрацией	любой
GET	`/models/{model_id}`	Получить модель	любой

Параметры фильтрации для `GET /models`: `name`, `team_id`, `task_type`

Версии

Метод	Путь	Описание	Права
POST	`/models/{model_id}/versions`	Создать новую версию	своя команда
GET	`/models/{model_id}/versions`	История версий	любой
GET	`/models/{model_id}/versions/{version_id}`	Детали версии	любой
POST	`/models/{model_id}/versions/{version_id}/upload-url`	Получить pre-signed URL для загрузки артефакта	своя команда
GET	`/models/{model_id}/versions/{version_id}/download-url`	Получить pre-signed URL для скачивания	любой

Метод	Путь	Описание	Права
PATCH	`/models/{model_id}/versions/{version_id}/status`	Сменить статус жизненного цикла	admin / team_lead

Статусы жизненного цикла: `staging` → `production` → `archived`. Только одна версия модели может иметь статус `production` одновременно — при переводе в `production` предыдущая версия автоматически переходит в `archived`.

Схема БД

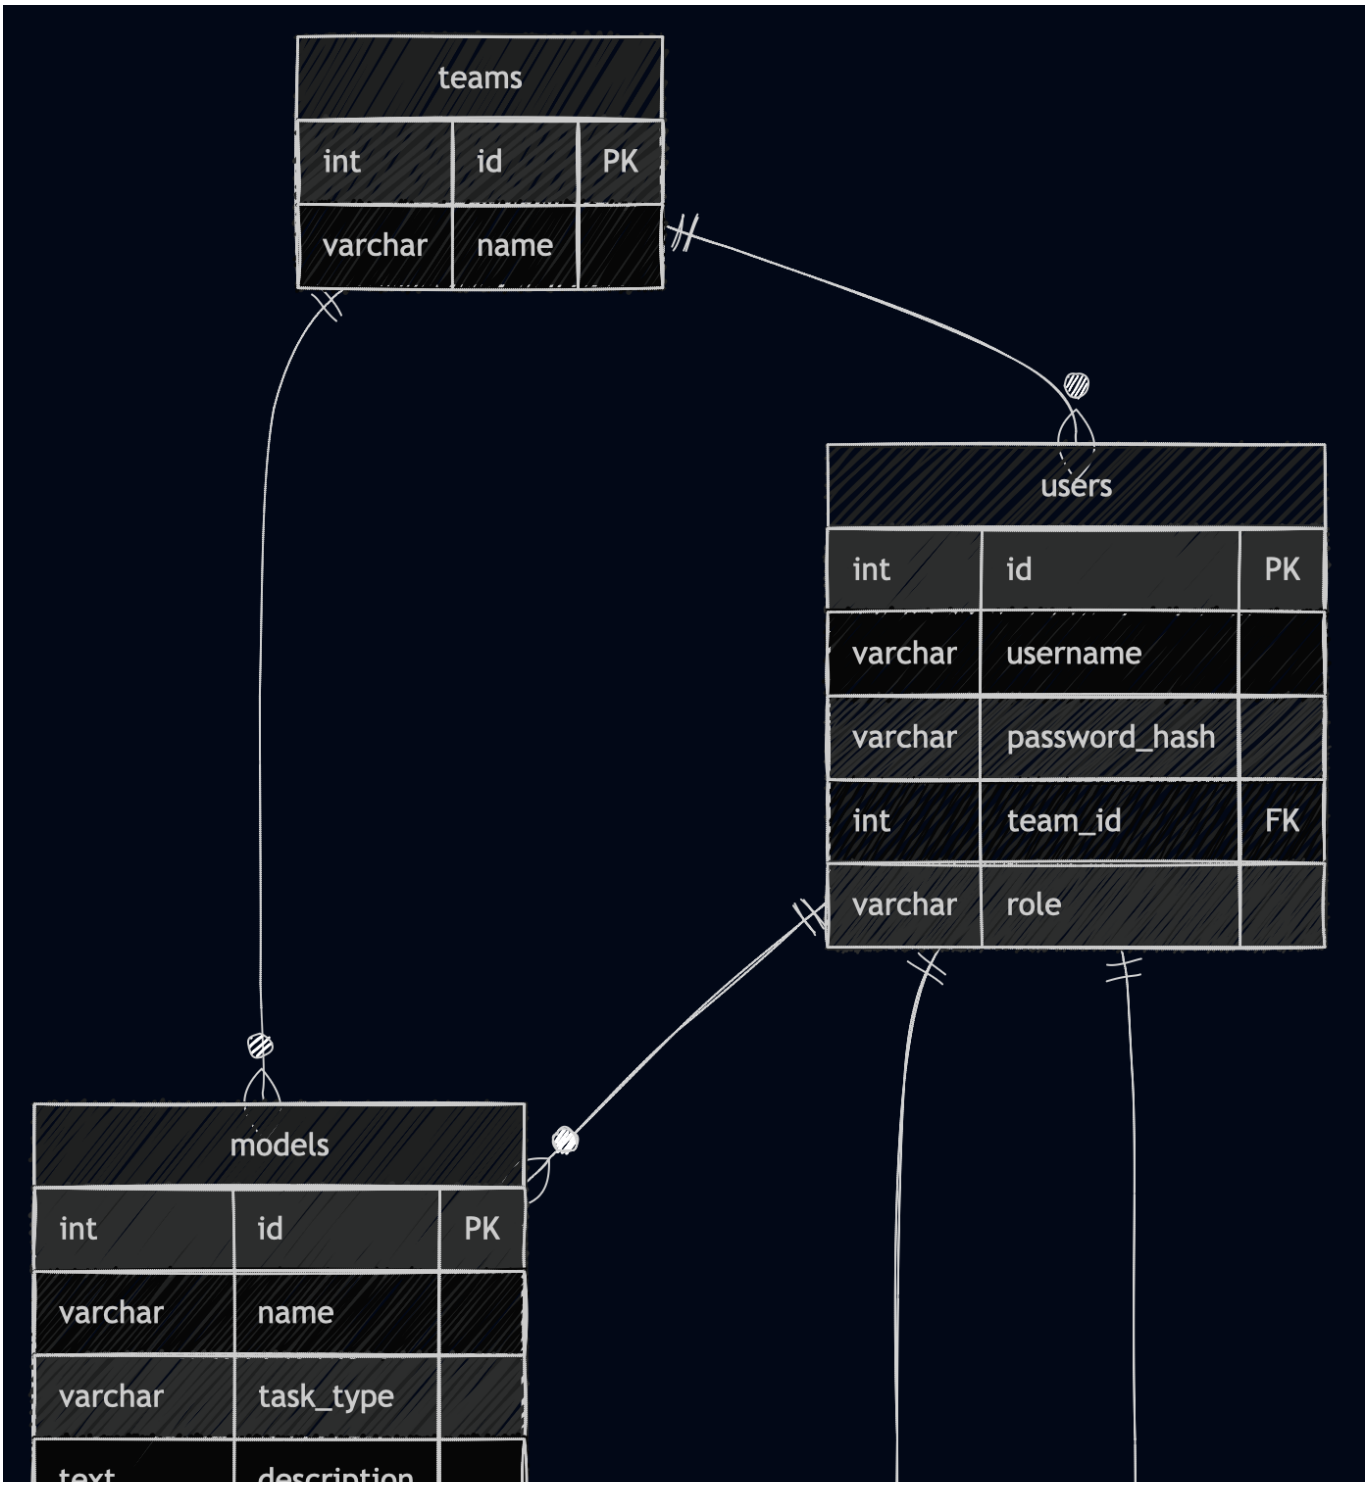

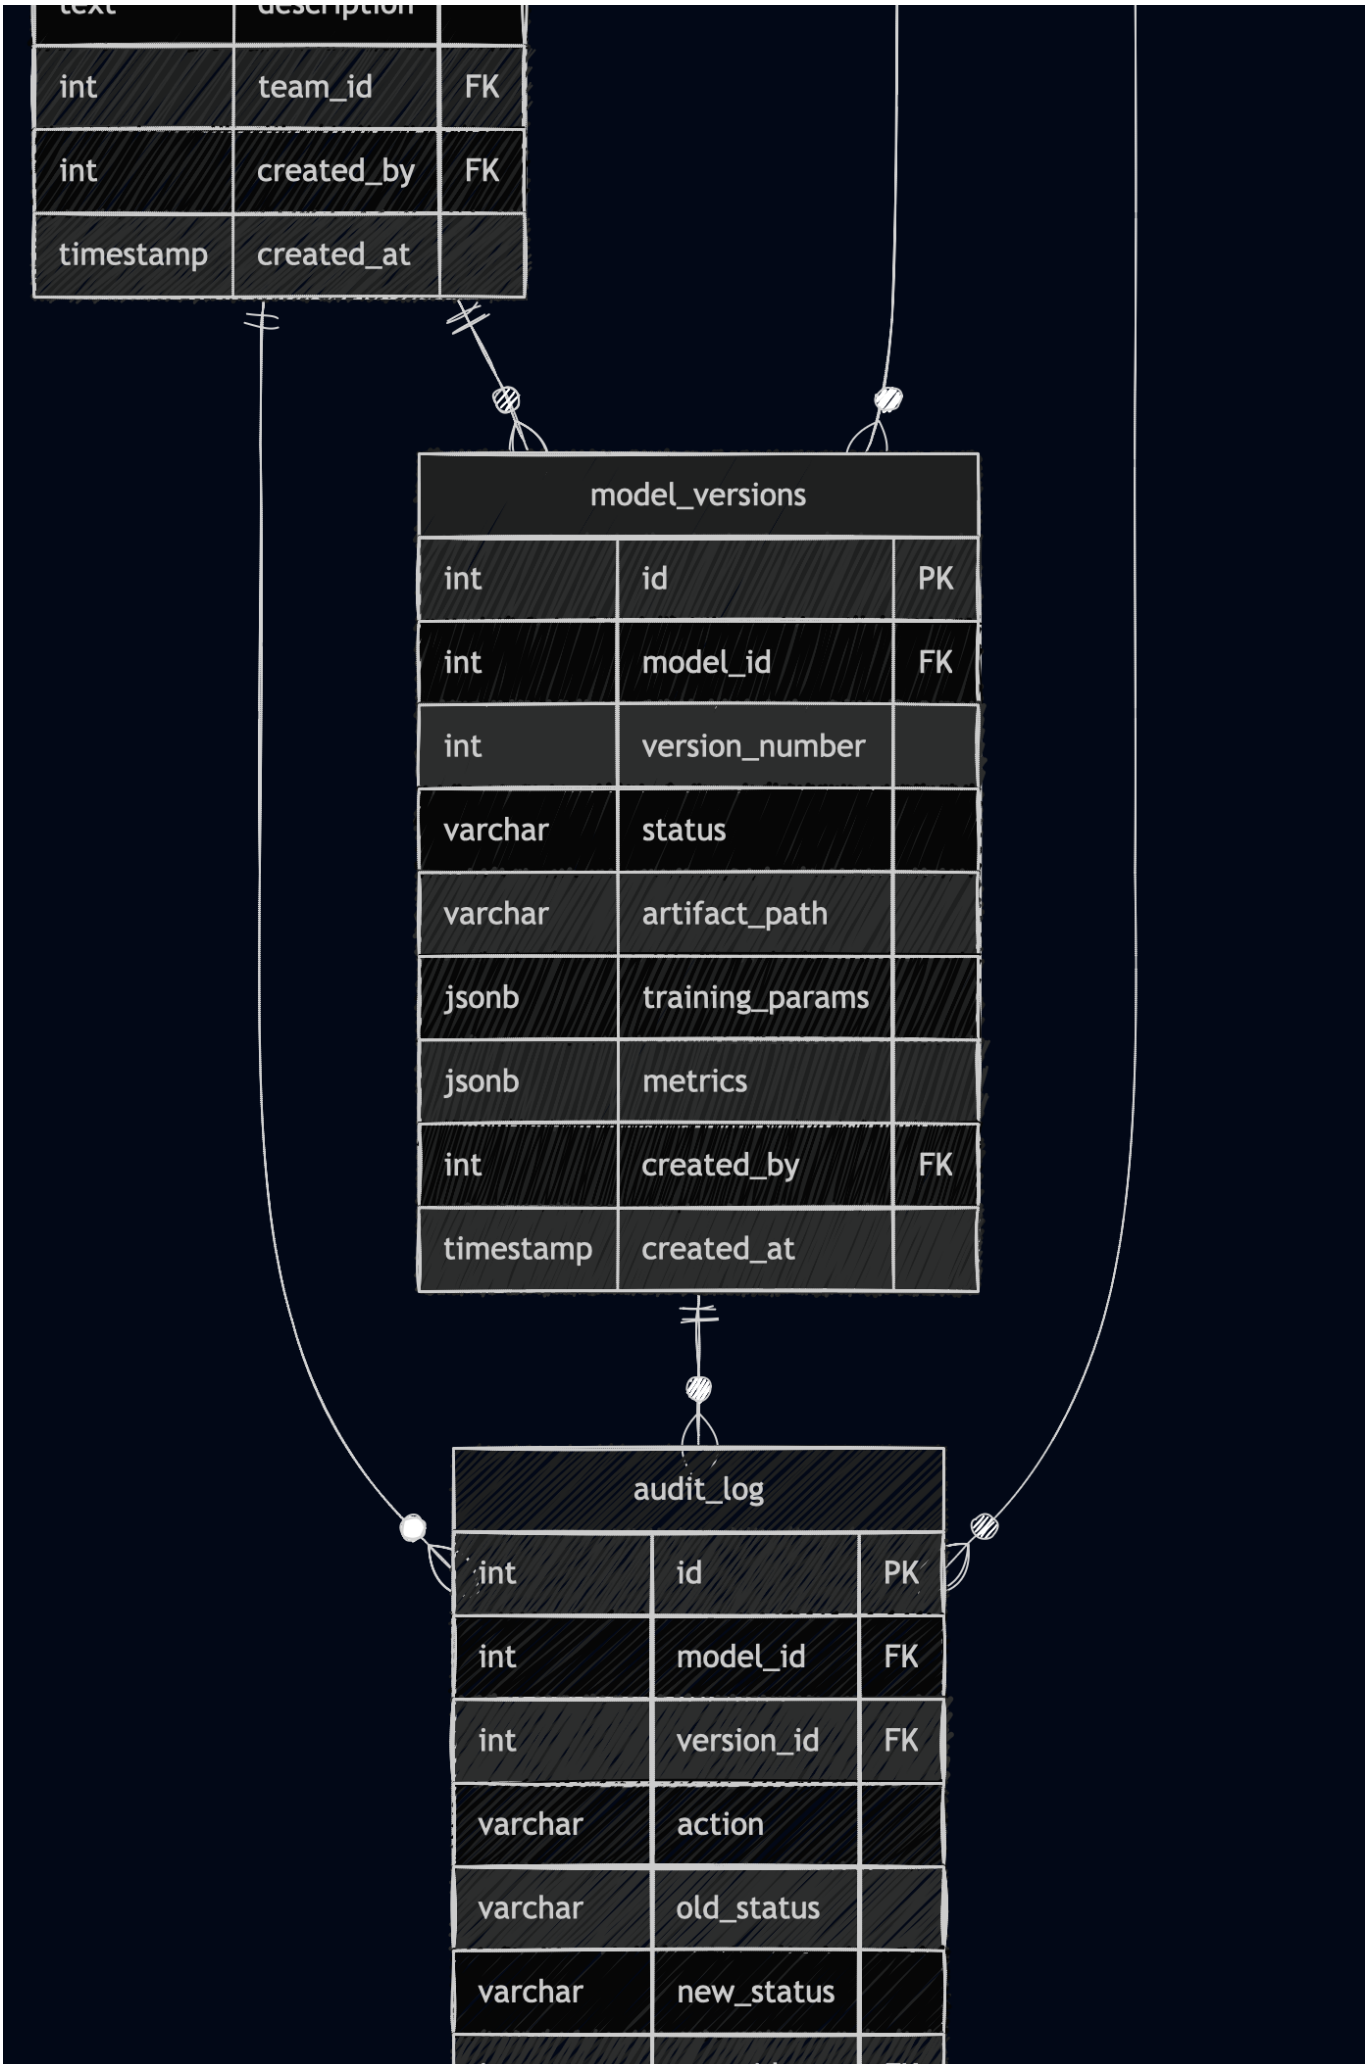
text
description
int
team_id
FK
int
created_by
FK
timestamp
created_at
model_versions
int
id
PK
int
model_id
FK
int
version_number
varchar
status
varchar
artifact_path
jsonb
training_params
jsonb
metrics
int
created_by
FK
timestamp
created_at
audit_log
int
id
PK
int
model_id
FK
int
version_id
FK
varchar
action
varchar
old_status
varchar
new_status

Таблицы

teams — команды.

users — пользователи. `role`: `member`, `team_lead`, `admin`.

models — сущность модели. Одна модель может иметь множество версий.

model_versions — версия модели. `version_number` инкрементируется в рамках модели. `status`: `staging` → `production` → `archived`. `training_params` и `metrics` — JSONB, конкретные метрики и параметры как схема не фиксируется.

audit_log — лог изменений. `action`: `create_model`, `create_version`, `status_changed`.